Suffix Automaton

Andrés Valencia Oliveros[1,2]

Facultad de Ingeniería, Diseño e Innovación
Institución Universitaria Politécnico Grancolombiano
Bogotá, Colombia

Resumen

Keywords: autómata finito, autómata de sufijo, coincidencia de cadenas.

1. Introducción

2. Grafo dirigido

Un grafo $G(V, E)$ es una colección de puntos, llamados vértices o nodos $V = \{v_1, v_2, \dots\}$, y segmentos de línea que conectan esos puntos, llamados aristas o arcos (en inglés *edges*) $E = \{e_1, e_2, \dots\}$; cada arista e tiene dos *puntos finales*, que son vértices.

Un digrafo o grafo dirigido $G(V, E)$ se define de manera similar a un grafo, excepto que el par de *puntos finales* (u, v) de cada arista ahora está ordenado. Se escribe $u \xrightarrow{e} v$, dónde u es el vértice inicial de e; y v es el vértice final de e. Se dice que la arista e está dirigida de u a v [1].

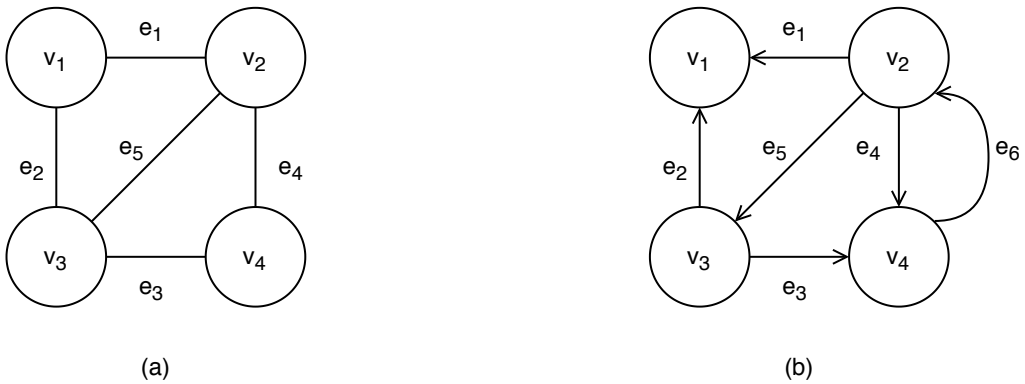

Figura 1. Tipos de grafos. (a) No dirigido. (b) Dirigido o digrafo.

[1] GitHub: anvalenciao
[2] Email: anvalenciao@poligran.edu.co

3. Autómata finito determinista

Formalmente, un autómata finito es una 5-tupla $(Q, \Sigma, q_0, \delta, F)$ donde:

- Q, es un conjunto finito de estados;
- Σ, es un conjunto finito de símbolos llamado alfabeto;
- $q_0 \in Q$ es el estado inicial;
- $\delta \colon Q \times \Sigma \to Q$ es una función de transición;
- $F \subseteq Q$ es un conjunto de estados finales o de aceptación.

Un *Autómata Finito Determinista* (AFD), es un autómata/máquina que tiene un número finito de estados y además es un sistema determinista, es decir, para cada símbolo de entrada, se puede determinar el estado al que se moverá el autómata [2].

Un AFD está representado por un grafo dirigido llamado diagrama de estado.

- Los estados son representados por vértices o nodos $Q = \{S_1, S_2, S_3, \dots\}$.
- Las aristas o arcos etiquetados con un alfabeto Σ, representan las transiciones δ.
- El estado inicial q_0 se denota por una sola arista entrante vacía.
- El o los estados finales F están indicados por círculos dobles.
- Cada transición se escribe $\delta(q_1, \sigma) = q_2$, también se puede denotar como $q_1 \xrightarrow{\sigma} q_2$.

Ejemplo 3.1 El siguiente ejemplo es de un AFD L, con un alfabeto binario, que reconoce el lenguaje regular conformado exclusivamente por las cadenas con un número par de ceros y un número par de unos.

$M = (Q, \Sigma, q_0, \delta, F)$ donde:

- $Q = \{S_1, S_2, S_3, S_4\}$
- $\Sigma = \{0, 1\}$
- $q_0 = S_1$
- $F = \{S1\}$
- $\delta : \delta(S_1, 0) = S_3, \delta(S_1, 1) = S_2, \delta(S_2, 0) = S_4, \delta(S_2, 1) = S_1, \delta(S_3, 0) = S_1, \delta(S_3, 1) = S_4, \delta(S_4, 0) = S_2, \delta(S_4, 1) = S_3$

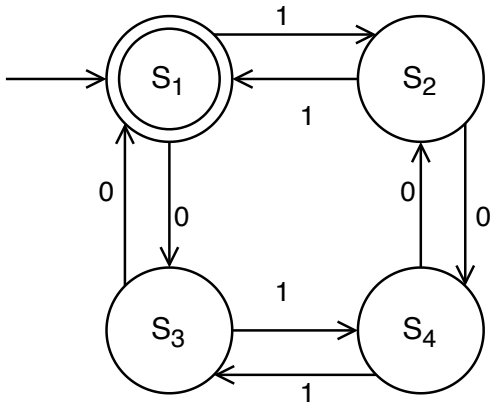

Figura 2. El diagrama de estado de L

El lenguaje reconocido por L es el lenguaje regular dado por la expresión regular [3]:

$$^(00|11|(01|10)(00|11)^*(01|10))^*\$$$

La Figura 2 da un ejemplo de un autómata simple M que acepta la cadena:

$$100110101100101001000 1$$

4. Autómata de sufijo

Un autómata de sufijo es una estructura de datos eficiente y compacta, también conocido como Directed Acyclic Word Graph (DAWG), es el AFD mínimo, que reconoce el conjunto de sufijos de una cadena $S = s_1 s_2 s_3 \dots s_n$ [4], es decir, se puede usar un autómata de sufijo para determinar si una cadena S es una subcadena en tiempo lineal en su longitud $O(|S|)$ [5].

Teorema 4.1 (Principal) *El tamaño de un autómata sufijo de una cadena S es $O(|S|)$. El autómata puede ser implementado en tiempo $O(|S| \times log\ card(A))$ y $O(|S|)$ espacio extra [6].*

4.1. Propiedades

El autómata de sufijo contiene información sobre todas las subcadenas de la cadena S. Para construir un autómata de sufijo en tiempo lineal, es necesario comprender dos conceptos *End Positions* y *Suffix Links*.

4.1.1. End Positions (endpos)

Los estados del autómata no son subcadenas, los estados representan clases de equivalencia. Cada subcadena de una cadena pertenece a una clase de equivalencia llamada *endpos* [7].

Definición 4.1 endpos(t): El conjunto de todas las posiciones en la cadena S donde termina la subcadena t [8].

Ejemplo 4.1 Sea t_1 = "*bc*" y t_2 = "*abc*" subcadenas de S = "*abcdbc*", entonces $endpos(t_1) = \{3, 6\}$ y $endpos(t_2) = \{3\}$ [8]. Sea t = "*bra*" una subcadena de S = "*abracadabra*", entonces $endpos(t) = \{3, 10\}$. Nótese que $endpos(t)$ es un conjunto cuyos elementos son posiciones finales de t en todas sus ocurrencias en S [7].

Dos subcadenas, t_1 y t_2, son endpos-equivalentes sí y sólo si $endpos(t_1) = endpos(t_2)$.

Ejemplo 4.2 Sea t_1 = "*abra*", t_2 = "*bra*", t_3 = "*ra*", t_4 = "*a*" subcadenas de S = "*abracadabra*", entonces $endpos(t_1) = \{3, 10\}, endpos(t_2) = \{3, 10\}, endpos(t_3) = \{3, 10\}, endpos(t_4) = \{0, 3, 5, 7, 10\}$.

S

a	b	r	a	c	a	d	a	b	r	a
0	1	2	3	4	5	6	7	8	9	10

Por lo tanto, $endpos(t_1), endpos(t_2), endpos(t_3)$ son endpos-equivalentes, lo que equivale a decir que una de las palabras t_1, t_2, t_3 es un sufijo de la otra. Nótese que $endpos(t_{1 \leq 3})$ y $endpos(t_4)$ no lo son.

4.1.2. Suffix Links (endpos)

Definición 4.2 link(Q): punta a la clase de equivalencia *endpos* definida por ."el sufijo más largo de w que no pertenece a Q"[8].

5. Algoritmo

5.0.1. Pseudocódigo

Algoritmo 5.1 *Suffix Automaton - let δ be the transition function of (Q, i, T, E)*

```
1:  function SA(x)
2:      (Q, E) ← (∅, ∅)
3:      i ← State-Creation
4:      Length[i] ← 0
5:      F[i] ← UNDEFINED
6:      last ← i
7:      for ℓ from 1 up to |x| do
8:          sa_extend(ℓ)
9:      end for
10:     T ← ∅
11:     p ← last
12:     while p ≠ UNDEFINED do
13:         T ← T + {p}
14:         p ← F[p]
```

```
    end while
    return (( Q, i, T, E ), Length, F)
end function
```

Algoritmo 5.2 *Suffix Automaton Extend*

```
function SA_EXTEND(ℓ)
    sa[i] ← x_ℓ
    newlast ← State-Creation
    Length[newlast] ← Length[last] + 1
    p ← last
    while p ≠ UNDEFINED and δ(p, a) = UNDEFINED do
        E ← E + {(p, a, newlast)}
        p ← F[p]
    end while
    if p = UNDEFINED then
        F[newlast] ← i
    else
        q ← δ(p, a)
        if Length[q] = Length[p] + 1 then
            F[newlast] ← q
        else
            q′ ← State-Creation
            for each letter b such that δ(q, b) ≠ UNDEFINED do
                E ← E + {(q′, b, δ(q, b))}
            end for
            Length[q′] ← Length[p] + 1
            F[newlast] ← q′
            F[q′] ← F[q]
            F[q] ← q′
            while p ≠ UNDEFINED and δ(p, a) = q do
                E ← E − {(p, a, q)} + {(p, a, q′)}
                p ← F[p]
            end while
        end if
    end if
    last ← newlast
end function
```

[6]

6. Aplicación

```
01 - helloworld
02 - elloworldh
03 - lloworldhe
04 - loworldhel
05 - oworldhell
06 - worldhello
07 - orldhellow
08 - rldhellowo
09 - ldhellowor
10 - dhelloworl
```

(a) 10 = dhelloworl

```
01 - amandamanda
02 - mandamandaa
03 - andamandaam
04 - ndamandaama
05 - damandaaman
06 - amandaamand
07 - mandaamanda
08 - andaamandam
09 - ndaamandama
10 - daamandaman
11 - aamandamand
```

(b) 11 = aamandamand

```
01 - dontcallmebfu
02 - ontcallmebfud
03 - ntcallmebfudo
04 - tcallmebfudon
05 - callmebfudont
06 - allmebfudontc
07 - llmebfudontca
08 - lmebfudontcal
09 - mebfudontcall
10 - ebfudontcallm
11 - bfudontcallme
12 - fudontcallmeb
13 - udontcallmebf
```

(c) 6 = allmebfudontc

```
01 - aaabaaa
02 - aabaaaa
03 - abaaaaa
04 - baaaaaa
05 - aaaaaab
06 - aaaaaba
07 - aaaabaa
```

(d) 5 = aaaaaab

Figura 3. Problema: *UVA 719 - Glass Beads*. Casos de entrada que contienen la descripción del collar y el número de la perla que es la primera en la peor separación posible. Cada perla está representada por un carácter en minúscula del alfabeto inglés (a–z), donde $a < b < ... < z$. (a) *helloworld*. (b) *amandamanda*. (c) *dontcallmebfu*. (d) *aaabaaa*.

Implementación 1: Caption

```
1  /**
```

```
 * $ g++ -o GlassBeads GlassBeads.cpp
 * $ ./GlassBeads < Input.in > Output.out
 */
#include<bits/stdc++.h>

using namespace std;

struct state {
    int len, link;
    map<char, int> next;
};

vector<state> st;
int sz, last;

void sa_init(int size) {
    st.clear();
    st.resize(2 * size);
    st[0].len = 0;
    st[0].link = -1;
    sz = last = 0;
    sz++;
}

void sa_extend (char c) {
    int cur = sz++;
    st[cur].len = st[last].len + 1;
    int p = last;
    while (p != -1 && !st[p].next.count(c)) {
        st[p].next[c] = cur;
        p = st[p].link;
    }
    if (p == -1)
        st[cur].link = 0;
    else {
        int q = st[p].next[c];
        if (st[p].len + 1 == st[q].len)
            st[cur].link = q;
        else {
            int clone = sz++;
            st[clone].len = st[p].len + 1;
            st[clone].next = st[q].next;
            st[clone].link = st[q].link;
            while (p != -1 && st[p].next[c] == q) {
                st[p].next[c] = clone;
                p = st[p].link;
            }
            st[q].link = st[cur].link = clone;
        }
    }
    last = cur;
}

void sa(string x) {
    int xsize = x.size();
    sa_init(xsize);
    for(int i = 0; i < xsize; i++) {
        sa_extend(x[i]);
    }
}

int UVa719_GlassBeads(const string S) {
    int at = 0;
    int length = 0;
    int ssize = S.size();
    while(length != ssize) {
        for (auto it : st[at].next) {
            at = it.second;
            length++;
            break;
```

```
72            }
73        }
74        return (st[at].len - 1) - ssize + 2LL;
75    }
76
77    int main() {
78        ios::sync_with_stdio(false);
79        cin.tie(nullptr);
80        int N;
81        cin >> N;
82        while(N--) {
83            string A;
84            cin >> A;
85            string AA = A + A;
86            sa(AA);
87            cout << UVa719_GlassBeads(A) << endl;
88        }
89        return 0;
90    }
```

Glosario de términos

AFD *Autómata Finito Determinista*. 2, 3

alfabeto Conjunto finito de símbolos. Un alfabeto se indica normalmente con Σ, que es el conjunto de letras en un alfabeto. 2

cadena Una cadena finita formada por la concatenación de un número de símbolos. 3

puntos finales Dos vértices conectados por una arista. 1

subcadena Una subcadena (segmento, subpalabra o factor) de una cadena es cualquier secuencia de símbolos consecutivos que aparecen en la cadena. En lenguaje formal, t es una subcadena de S sí y sólo si existe $x, y \in \Sigma^*$ tal que $S = xty$. 3

símbolo Un dato arbitrario que tiene algún significado o efecto en la máquina. A estos símbolos también se les llama "letras" o "átomos". 2

Referencias

[1] S. Even, *Graph algorithms*. Cambridge University Press, 2011.

[2] Wikipedia, "Autómata finito — wikipedia, la enciclopedia libre," 2020.

[3] T. Biegeleisen, "regex - Regular expression for even number of 0's and even number of 1's - Stack Overflow," 2015.

[4] Wikipedia contributors, "Suffix automaton — Wikipedia, the free encyclopedia," 2020.

[5] M. Mohri, P. Moreno, and E. Weinstein, "General suffix automaton construction algorithm and space bounds," *Theor. Comput. Sci.*, vol. 410, p. 3553–3562, Sept. 2009.

[6] M. Crochemore and C. Hancart, *Automata for Matching Patterns*, pp. 399–462. Berlin, Heidelberg: Springer Berlin Heidelberg, 1997.

[7] S. A. P. Cali, "Autómatas de sufijos."

[8] Akshay Jaggi, "Suffix automata," 2016.